

Análisis Exploratorio del Dataset Jigsaw Toxic Comment Classification Challenge

Dataset de comentarios tóxicos de Wikipedia

159,571 comentarios etiquetados con seis categorías de toxicidad

1 Hipótesis

Antes de cualquier modelado se formularon cinco hipótesis explícitas que guían el análisis y definen qué constituye evidencia a favor o en contra.

H1. Las etiquetas de toxicidad no son independientes. Existe una estructura de co-ocurrencia donde algunas etiquetas aparecen juntas con frecuencia mucho mayor que la esperada por azar (por ejemplo, **obscene** e **insult**). Si esto se confirma, modelar cada etiqueta por separado pierde información y un modelo multietiqueta es preferible.

H2. Los comentarios tóxicos tienen distribuciones de longitud y proporción de mayúsculas distintas a los no tóxicos. Los comentarios tóxicos serían más cortos y con más mayúsculas. Esta hipótesis se basa en que la agresividad tiende a expresarse en fragmentos cortos y enfáticos.

H3. El desbalance extremo de clases (la clase mayoritaria supera el 89%) hace que la exactitud sea una métrica engañosa. Métricas como F1 por etiqueta y AUC-ROC son necesarias para evaluar correctamente.

H4. Los features textuales simples (longitud, mayúsculas, signos de exclamación) tienen poder discriminativo limitado pero no trivial. Un modelo lineal que use solo estos features logrará AUC-ROC por encima de 0.5 pero lejos de lo que un modelo con representación textual rica (TF-IDF, embeddings) alcanzaría.

H5. Las etiquetas **threat** e **identity_hate** son las más difíciles de predecir debido a su escasez (0.30% y 0.88%) y a su relativamente baja correlación con las demás etiquetas.

2 Exploración de datos

2.1 Vista general del dataset

El dataset contiene 159,571 comentarios provenientes de páginas de discusión de Wikipedia, etiquetados por anotadores humanos con seis categorías de toxicidad. No hay valores faltantes ni filas duplicadas. La integridad de los datos es completa.

Sin valores faltantes

Figura 1: Vista general del dataset. Sin valores faltantes en ninguna columna.

Sin valores faltantes

Figura 2: Reporte de valores faltantes. Todas las columnas tienen 0% de missing.




Figura 3: Reporte de duplicados. Cero filas duplicadas en el dataset.

3 Distribución de etiquetas

La distribución de etiquetas revela un desbalance extremo. La clase «comentario limpio» (sin ninguna etiqueta) representa 89.83% del dataset. Las seis categorías de toxicidad tienen prevalencias que van de 0.30% (**threat**) a 9.58% (**toxic**).




Figura 4: Distribución de etiquetas. Barras de conteo (izquierda) y número de etiquetas por comentario (derecha).

Se observan tres niveles de prevalencia:

- **Extrema** (menor a 1%): **severe_toxic** (1.00%), **threat** (0.30%), **identity_hate** (0.88%). Estas etiquetas tienen muy pocos ejemplos positivos, lo que incrementa la varianza del estimador y dificulta la separación entre señal y ruido.
- **Severa** (1–5%): **insult** (4.94%).
- **Moderada** (5–10%): **toxic** (9.58%), **obscene** (5.29%).

Solo 10.17% de los comentarios tienen al menos una etiqueta tóxica. El 6.18% son multietiqueta (dos o más etiquetas simultáneamente). Esto confirma que la mayoría de los comentarios son limpios y que la clasificación enfrenta un problema de desbalance severo.

4 Co-ocurrencia entre etiquetas

Las etiquetas no son independientes. La co-ocurrencia entre pares de etiquetas revela una estructura jerárquica fuerte.




Figura 5: Porcentaje condicional $P(\text{etiqueta_col} \mid \text{etiqueta_row})$ y coeficiente Phi entre etiquetas.

Los hallazgos clave son:

- **severe_toxic** es un subconjunto perfecto de **toxic**. El 100% de los comentarios **severe_toxic** también están etiquetados como **toxic**. No es una categoría independiente sino una intensificación dentro de **toxic**.
- **obscene** e **insult** co-ocurren en 72.8% de los casos de **obscene** y en 78.1% de los casos de **insult**. Su coeficiente Phi es 1.06, el par más alto del dataset. Estas dos etiquetas capturan un fenómeno compartido (el lenguaje ofensivo-dirigido) y rara vez aparecen aisladas.
- **threat** es la etiqueta más independiente. Su co-ocurrencia más alta es con **obscene** (63.0%) y su Phi promedio con las demás es 0.04. Captura un patrón conductual distinto (la amenaza explícita) que no se solapa fuertemente con el resto.
- Todos los pares de etiquetas fallan la prueba de independencia Chi-cuadrada ($p < 0.001$). Ningún par es estadísticamente independiente.

Esta estructura tiene implicaciones directas para el modelado. Un enfoque que entrene clasificadores binarios independientes ignora la covarianza entre etiquetas y pierde información. Un modelo multietiqueta que capture estas dependencias (por ejemplo, una red con salida sigmoide y pérdida binaria por etiqueta, o classifier chains) es preferible desde el punto de vista estadístico.

5 Features textuales derivados

Dado que el predictor principal es texto libre, se derivaron seis features numéricos simples a partir de cada comentario: longitud del texto (`text_len`), conteo de palabras (`word_count`), proporción de mayúsculas (`caps_ratio`), proporción de signos de exclamación (`exclaim_ratio`), proporción de signos de interrogación (`question_ratio`) y proporción de palabras únicas (`unique_word_ratio`).




Figura 6: Resumen estadístico de variables continuas. Distribuciones con sesgo positivo extremo.




Figura 7: Reporte de outliers por IQR. Las variables ratio tienen hasta 23% de outliers.

Todas las variables tienen distribuciones fuertemente sesgadas y colas pesadas. Los ratios de exclamación e interrogación tienen más de 14% de outliers por el método IQR. Esto confirma que los features no son normales y que los métodos no paramétricos son necesarios para las comparaciones de grupos.




Figura 8: Distribuciones de features textuales comparando comentarios tóxicos vs limpios (percentil 99).

Las distribuciones muestran diferencias visibles entre grupos. Los comentarios tóxicos tienden a ser más cortos y a usar más mayúsculas y exclamaciones. Sin embargo, las distribuciones se solapan sustancialmente, lo que indica que estos features simples no separan los grupos por sí solos.

6 Pruebas estadísticas

6.1 Correlación entre etiquetas




Figura 9: Matriz de correlación Pearson entre etiquetas.




Figura 10: Matriz de correlación Spearman entre etiquetas. Idéntica a Pearson por ser variables binarias.

Las correlaciones Pearson y Spearman coinciden porque las variables son binarias. Los pares con correlación más alta son **obscene–insult** ($r = 0.74$) y **toxic–obscene** ($r = 0.68$). Los pares con correlación más baja son **threat–identity_hate** ($r = 0.12$) y **threat–severe_toxic** ($r = 0.12$). La etiqueta **threat** es consistentemente la menos correlacionada con las demás, lo que refuerza su relativa independencia.




Figura 11: Factor de Inflación de Varianza entre etiquetas. Todos los valores son menores a 3. El VIF máximo es 2.69 (**obscene**). No hay multicolinealidad problemática (el umbral convencional es $VIF > 10$). Esto significa que cada etiqueta aporta información distinta aunque estén correlacionadas. Un modelo puede usar las seis etiquetas como predictores sin que la colinealidad distorsione los coeficientes.

6.2 Asociación entre features textuales y etiquetas




Figura 12: Correlación point-biserial entre features textuales y cada etiqueta de toxicidad.

El feature con mayor poder discriminativo es **caps_ratio**, que alcanza $r = 0.22$ con **toxic** y $r = 0.17$ con **severe_toxic** y **insult**. Le sigue **exclaim_ratio** con r entre 0.09 y 0.13. Los features de longitud (**text_len**, **word_count**) tienen correlaciones débiles y negativas (r alrededor de -0.05). **question_ratio** es esencialmente ruido para la mayoría de etiquetas ($r < 0.03$, no significativo para **severe_toxic** e **identity_hate**).

La interpretación es que los features de «énfasis» (mayúsculas, exclamaciones) capturan parcialmente la agresividad del comentario, mientras que la longitud apenas discrimina y los signos de interrogación no discriminan en absoluto.

6.3 Normalidad




Figura 13: Pruebas de normalidad con histogramas y Q-Q plots. Ningún feature es normal.

Las pruebas de Shapiro-Wilk y D'Agostino-Pearson rechazan la normalidad para todos los features ($p < 0.001$). Los sesgos extremos (exclaim_ratio: 25.4, question_ratio: 23.1) y la kurtosis (hasta 1131) confirman distribuciones con colas pesadas y concentración masiva cerca de cero. Este resultado invalida el uso de t-test y ANOVA para comparar grupos, y justifica el uso de Mann-Whitney U y Kruskal-Wallis como pruebas no paramétricas.

6.4 Comparación de grupos




Figura 14: Tamaño del efecto (rank-biserial correlation) de cada feature al comparar tóxicos vs limpios.

Las diferencias entre grupos son estadísticamente significativas (Mann-Whitney U, $p < 0.05$) para todos los features excepto `question_ratio` en etiquetas raras. Sin embargo, los tamaños de efecto son pequeños a moderados. `caps_ratio` tiene el efecto más grande ($r_{rb} = 0.46$ con `any_toxic`), seguido de `exclaim_ratio` ($r_{rb} = 0.31$). `text_len` y `word_count` tienen efectos débiles (r_{rb} entre 0.19 y 0.24).

Esto significa que las diferencias son reales pero modestas. Los features simples capturan solo una fracción de la señal discriminativa. La representación textual rica (TF-IDF, n-gramas, embeddings) es necesaria para alcanzar un rendimiento competitivo.

7 Comparación de modelos baseline

Se compararon LogisticRegression (con `class_weight="balanced"`) y RandomForestClassifier (100 árboles, `max_depth=10`, `class_weight="balanced"`) usando validación cruzada estratificada de 5 pliegues sobre una submuestra de 30,000 comentarios. La submuestra preserva la distribución de la variable `any_toxic`.




Figura 15: F1-score y AUC-ROC por etiqueta para LogisticRegression y RandomForest con features textuales simples.

Los resultados confirman la hipótesis H4. Los AUC-ROC oscilan entre 0.56 (**identity_hate** con RF) y 0.79 (**severe_toxic** con RF), lo que está por encima del azar (0.5) pero lejos del rendimiento reportado por soluciones líderes en la competencia original ($AUC > 0.95$ con TF-IDF y modelos de deep learning). Random Forest supera a LogisticRegression en F1 para las etiquetas más prevalentes, pero LogisticRegression mantiene AUC competitivos y ofrece interpretabilidad directa de los coeficientes.

Los F1-scores son bajos en todas las etiquetas (entre 0.02 y 0.30), lo cual es esperado con features tan limitados y desbalance severo. Las etiquetas con menor prevalencia (**threat** e **identity_hate**) obtienen los F1 más bajos, confirmando la hipótesis H5.

La elección de `class_weight="balanced"` se justifica porque ajusta la función de pérdida para compensar el desbalance, evitando que el modelo ignore la clase minoritaria. La elección de 5-fold CV estratificado garantiza que cada pliegue preserve la distribución de clases. El `max_depth=10` en Random Forest previene el sobreajuste en la submuestra, aunque sacrifica capacidad de capturar interacciones profundas.

8 Diagnóstico Toolbelt

Se ejecutó el diagnóstico completo del paquete `statistical_toolbelt` sobre los features derivados con la variable `any_toxic` como target.

Sin valores faltantes

Figura 16: Vista general del dataset de features.




Figura 17: Evaluación de aptitud ML. Veredicto: READY.

El diagnóstico de aptitud arrojó veredicto READY sin advertencias críticas. El desbalance de clases (89.83% clase mayoritaria) está por debajo del umbral de alerta (90%). No se detectó leakage entre features y target. El ratio filas/features (5000:1) es más que suficiente.




Figura 18: Recomendaciones de modelos del toolbelt. LightGBM/XGBoost como candidato principal.

El toolbelt recomienda LightGBM/XGBoost como candidato principal (score 9.51), seguido de CatBoost (9.09). LogisticRegression aparece como baseline interpretable (7.22). Estas recomendaciones coinciden con la práctica actual en clasificación tabular, aunque para este problema específico la representación textual es más determinante que la elección del algoritmo.

9 Estructura jerárquica de etiquetas

El análisis de co-ocurrencia reveló una posible estructura jerárquica entre etiquetas. La pregunta central es si las etiquetas forman un orden parcial donde la presencia de una etiqueta implica la presencia de otra.




Figura 19: Tabla de implicación $P(B|A)$ y grafo de jerarquía aproximada. Aristas donde $P > 0.50$.

La única implicación estricta es **severe_toxic** $\rightarrow$ **toxic**, con cero violaciones en 159,571 comentarios. Todas las demás sub-etiquetas (**obscene**, **insult**, **threat**, **identity_hate**) co-ocurren con **toxic** entre 92.7% y 93.9% de los casos, pero cada una tiene entre 6% y 7.3% de violaciones donde la sub-etiqueta está presente sin que **toxic** lo esté.




Figura 20: Violaciones de implicaciones fuertes ($P(B|A) \geq 0.90$). Barras rojas para violaciones $> 5\%$.

Las violaciones más notables son:

- **obscene**=1 y **toxic**=0: 523 casos (6.19% de los comentarios **obscene**). De estos, 317 (60.6%) solo tienen la etiqueta **obscene** sin ninguna otra. Los ejemplos muestran lenguaje vulgar

(«Wanker», «damn») en contextos donde los anotadores no consideraron el comentario genéricamente tóxico.

- **insult=1** y **toxic=0**: 533 casos (6.77%). De estos, 301 (56.5%) son etiqueta única.
- **threat=1** y **toxic=0**: 29 casos (6.07%). De estos, 22 (75.9%) son etiqueta única. Los ejemplos incluyen advertencias de bloqueo administrativo en Wikipedia («you will be blocked») que fueron etiquetadas como amenazas pero no como toxicidad general.

9.1 ¿Forman un orden parcial?

Las etiquetas no forman un orden parcial estricto. La única relación de subconjunto perfecta es **severe_toxic** $\subset$ **toxic**. Las demás sub-etiquetas son subconjuntos aproximados de **toxic** con tasas de violación entre 6% y 7.3%. Estas violaciones no son errores de etiquetado sino que reflejan una diferencia de interpretación entre anotadores. Algunos anotadores consideran que un comentario puede ser obsceno o amenazante sin ser genéricamente tóxico. Esto significa que la etiqueta **toxic** no es un prerrequisito formal sino una categoría de severidad que la mayoría de anotadores activa junto con las sub-etiquetas, pero no todos.

La estructura observada tiene la forma de una jerarquía aproximada donde **toxic** es la raíz, **severe_toxic** es un subconjunto perfecto, y las cuatro etiquetas restantes son hijos aproximados con 93% de adherencia. Esta estructura puede explotarse en el modelado con dos enfoques complementarios. Primero, entrenar un modelo de detección de **toxic** como primer filtro y luego clasificar el sub-tipo entre los detectados. Segundo, usar una arquitectura con pérdida jerárquica que penalice más las predicciones que violen la estructura observada (por ejemplo, predecir **severe_toxic=1** y **toxic=0**).

10 Estabilidad de los resultados

Los resultados del modelado se reportaron como medias de validación cruzada sin intervalos de confianza. Esto impide determinar si las diferencias entre LogisticRegression y Random Forest son estadísticamente significativas o si son ruido del muestreo. Para resolver esto se ejecutó el mismo pipeline de modelado con 10 semillas diferentes, cada una con su propia submuestra estratificada de 30,000 comentarios y su propia partición de 5-fold CV. Los intervalos de confianza al 95% se calcularon sobre la distribución de las 10 medias.




Figura 21: F1-score y AUC-ROC con intervalos de confianza al 95% sobre 10 semillas. LR en azul, RF en rojo.




Figura 22: Coeficiente de variación del F1-score entre 10 semillas. Valores altos indican métrica inestable.

10.1 Resultados de estabilidad

Para las etiquetas prevalentes (**toxic**, **obscene**, **insult**), los F1-scores son estables con coeficientes de variación menores a 4%. Los AUC-ROC son aún más estables ($CV < 2\%$). Esto significa que las medias reportadas son estimaciones confiables para estas etiquetas.

Para **threat** e **identity_hate**, los F1-scores son altamente inestables. El F1 de **threat** con Random Forest tiene un CV de 33.9%, lo que significa que la métrica puede oscilar entre 0.005 y 0.024 solo por cambiar la semilla. El AUC de **threat** con LogisticRegression tiene un IC 95% de [0.62, 0.80], un rango de 18 puntos porcentuales. Esta inestabilidad refleja que con solo 93 ejemplos positivos en la submuestra, la varianza del estimador es intrínsecamente alta.

10.2 ¿LR vs RF es significativamente diferente?

La comparación de intervalos de confianza revela que la diferencia entre LR y RF es significativa (IC no se solapan) en F1 para **toxic**, **obscene** e **insult**, donde Random Forest supera consistentemente a LogisticRegression. En AUC-ROC, la diferencia es significativa para las mismas tres etiquetas más **severe_toxic**.

Sin embargo, para las etiquetas raras (**threat**, **identity_hate**), los IC se solapan ampliamente. La diferencia entre LR y RF en **threat** no es estadísticamente significativa ni en F1 ni en AUC. Lo mismo ocurre con **identity_hate**. Esto significa que no se puede afirmar que un modelo sea superior al otro para estas etiquetas con los datos disponibles. La recomendación práctica es no seleccionar el modelo basándose en las métricas de **threat** e **identity_hate** con features simples, porque la señal es insuficiente para distinguir entre algoritmos.

11 Analisis de sentimiento (VADER)

Se aplico VADER (Valence Aware Dictionary and sEntiment Reasoner) a los 159,571 comentarios para evaluar si la polaridad del sentimiento predice la toxicidad.




Figura 23: Distribucion del compound score por grupo (toxico vs limpio) y prevalencia de toxicidad por categoria de sentimiento.

Los comentarios con sentimiento negativo (compound < -0.05) tienen 22.1% de prevalencia de toxicidad, frente a 5.3% en neutros y 3.9% en positivos. La asociacion es real pero imperfecta. La mayoría de los comentarios negativos son limpios (critica constructiva, frustracion legitima), y 3,075 comentarios toxicos tienen sentimiento positivo (sarcasmo hostil, amenazas encubiertas).




Figura 24: Correlacion point-biserial entre features de sentimiento y etiquetas de toxicidad.

La correlacion mas fuerte es entre sent_neg y toxic ($r = 0.47$). Las correlaciones mas debiles son entre compound y threat ($r = -0.07$) y entre compound e identity_hate ($r = -0.10$). Esto confirma que el sentimiento captura valencia pero no intencion hostil.

11.1 Efecto de VADER en el modelo

Agregar features de VADER al baseline de texto simple mejora el AUC-ROC de LogisticRegression entre +0.15 y +0.25 segun la etiqueta. La mayor mejora se observa en severe_toxic

(+0.25 AUC) y la menor en identity_hate (+0.15). La combinacion texto+VADER+EMPATH supera sistematicamente a texto+VADER sola.




Figura 25: Incremento de AUC-ROC al agregar VADER y EMPATH al baseline de texto simple.




Figura 26: Relacion entre sentimiento y toxicidad. Los falsos negativos (positivos y toxicos) incluyen sarcasmo y amenazas encubiertas.

12 Analisis de categorias tematicas (EMPATH)

EMPATH clasifica texto en 194 categorias tematicas (hate, aggression, violence, swearing, ridicule, etc.). A diferencia de VADER que mide valencia, EMPATH captura tema e intencion, lo cual deberia alinearse mejor con las etiquetas de toxicidad.




Figura 27: Categorias EMPATH con mayor diferencia de media entre comentarios toxicos y limpios.

Las categorias mas activas en comentarios toxicos son swearing_terms (diferencia = 0.014), negative_emotion (0.012), ridicule (0.004) y hate (0.004). Esto confirma que la toxicidad se expresa predominantemente con lenguaje soez, emocion negativa, ridiculo y odio, no solo con valencia negativa.




Figura 28: Top 5 categorias EMPATH mas discriminativas por etiqueta de toxicidad.

La estructura semantica por etiqueta muestra patrones coherentes. swearing_terms domina en toxic, obscene e insult. kill y weapon son las mas discriminativas para threat. Para identity_hate, swearing_terms lidera pero hate tiene un r bajo (0.04), lo que sugiere que el odio identitario en Wikipedia se expresa mas con vulgaridad que con lexico explicito de odio.

12.1 EMPATH vs VADER




Figura 29: Poder discriminativo del mejor feature EMPATH vs el mejor feature VADER por etiqueta.

VADER sent_neg tiene correlaciones individuales mas altas que cualquier categoria EMPATH en 5 de 6 etiquetas porque sent_neg agrega toda la valencia negativa. Sin embargo, EMPATH supera a VADER en threat (kill $r=0.18$ vs sent_neg $r=0.12$), donde el lexico tematico es

mas informativo que la valencia. La combinacion de ambos conjuntos supera a cualquiera por separado.

12.2 Efecto de EMPATH en el modelo




Figura 30: AUC-ROC y F1-score por configuracion de features (texto, texto+VADER, texto+EMPATH, texto+VADER+EMPATH).




Figura 31: Incremento de AUC-ROC al agregar VADER, EMPATH o ambos al baseline de texto simple.

Los deltas de AUC respecto al baseline de solo texto son notablemente grandes. La combinacion texto+VADER+EMPATH alcanza AUC de 0.84 a 0.94 segun la etiqueta, un salto de +0.17 a +0.31 sobre el baseline de solo texto. EMPATH como conjunto es inferior a VADER como conjunto en 5 de 6 etiquetas, pero la combinacion de ambos supera sistematicamente a cualquiera por separado, confirmando que capturan dimensiones complementarias (tema, valencia, enfasis).

13 Modelo productivo: Classifier Chain LightGBM

El modelo productivo reemplaza el placeholder LogisticRegression por una cadena de clasificadores LightGBM que respeta la jerarquía de etiquetas documentada en el EDA. El orden de la cadena es **toxic** → **obscene** → **insult** → **severe_toxic** → **identity_hate** → **threat**, donde cada modelo recibe como features adicionales las probabilidades predichas por los modelos anteriores.

13.1 Features

El pipeline de features incluye:

1. **TF-IDF** (5,000 features, n-gramas 1-2, sublinear TF, min_df=3, max_df=0.95)
2. **Texto simple** (6 features: longitud, conteo de palabras, ratio de mayúsculas, ratio de exclamación, ratio de pregunta, diversidad léxica)
3. **VADER** (4 features: neg, neu, pos, compound)
4. **EMPATH** (15 categorías seleccionadas por correlación con any_toxic)

Total: 5,010 features de entrada por comentario.

13.2 Hiperparámetros

Cada etiqueta tiene configuración específica. Las etiquetas raras (**threat**, **identity_hate**, **severe_toxic**) usan más árboles (800-1000), mayor profundidad (9-11) y más hojas (127-255). Las etiquetas prevalentes (**toxic**, **obscene**, **insult**) usan 500 árboles con profundidad 7 y 63 hojas. Todas usan **scale_pos_weight** inverso a la frecuencia de la clase positiva, compensando el desbalance extremo (e.g., **threat** con peso 335:1).

13.3 Resultados




Figura 32: Curvas ROC por etiqueta. AUC-ROC macro = 0.9630.




Figura 33: AUC-ROC: LogisticRegression (L1, C=0.1) vs LightGBM Classifier Chain con IC 95% bootstrap.

Los AUC-ROC del modelo LightGBM son: toxic 0.9598, severe_toxic 0.9819, obscene 0.9799, threat 0.9549, insult 0.9710, identity_hate 0.9308. Macro-AUC = 0.9630. Los intervalos de confianza al 95% (bootstrap, 200 repeticiones) no se solapan con 0.5 en ninguna etiqueta.

La comparacion con LogisticRegression muestra que LR alcanza AUC marginalmente superiores en 4 de 6 etiquetas, pero las diferencias estan dentro de los IC 95% de LightGBM. LR con penalty L1 y C=0.1 realiza seleccion implicita de features en el espacio TF-IDF, lo que le da ventaja en representacion sparse. Sin embargo, LightGBM ofrece feature importance interpretable, umbral F2-optimo por clase y la estructura de cadena que modela dependencias entre etiquetas.

13.4 Feature importance




Figura 34: Top 10 features por etiqueta. Las features de la cadena (chain underscore) aparecen como las mas importantes en etiquetas posteriores.

Las features de la cadena dominan la importancia para etiquetas posteriores. Para **obscene**, chain_toxic (importancia 1433) supera a cualquier feature de entrada. Para **insult**, chain_obscene y chain_toxic juntas aportan mas que todos los TF-IDF. Para **threat**, caps_ratio es el feature de entrada mas importante, seguido de chain_identity_hate y chain_severe_toxic. Esto confirma que la estructura de dependencia entre etiquetas es la senal mas fuerte para las sub-etiquetas.

El lexico obsceno («fuck», «gay») aparece entre los top TF-IDF features para obscene e identity_hate respectivamente, validando que el TF-IDF captura senal lexica especifica.

13.5 Calibracion y umbrales




Figura 35: Calibracion de probabilidades por etiqueta. ECE = Expected Calibration Error.

toxic tiene el peor ECE (0.1172), lo que indica que sus probabilidades estan sobrecalibradas para predicciones altas. **threat** tiene el mejor ECE (0.0023) porque sus probabilidades estan concentradas cerca de 0 y la calibracion es trivialmente buena en ese rango.




Figura 36: Metricas por umbral de decision. El umbral F2-optimo se marca con linea punteada roja.

Los umbrales F2-optimos varian por etiqueta: toxic 0.52, obscene 0.70, insult 0.65, identity_hate 0.71, severe_toxic 0.49, threat 0.10. El umbral de 0.10 para **threat** refleja que la clase es tan rara (0.30%) que se necesita un umbral muy bajo para alcanzar recall aceptable (52%). En

produccion, el umbral debe ajustarse segun el costo relativo de falsos negativos (comentario amenazante no detectado) vs falsos positivos (moderacion excesiva).

14 Comparacion de modelos CPU-only

Se compararon seis modelos CPU-only sobre las mismas features (TF-IDF + densos) con el mismo split train/test (80/20, estratificado por any_toxic). Todos los modelos independientes se entrenan por etiqueta con class_weight=«balanced». La cadena LightGBM usa el orden jerarquico documentado en el EDA.

14.1 Modelos comparados

Modelo	Family	Loss	Tiempo (6 etiquetas)
LogisticRegression L1	Lineal	Log loss	75s
MultinomialNB	Bayesiano	Verosimilitud	less than 1s
ComplementNB	Bayesiano	Verosimilitud complementaria	less than 1s
LinearSVC	Lineal	Hinge loss	58s
SGDClassifier	Lineal	Log loss + elasticnet	3s
LightGBM Chain	Boosting	Binomial deviance	888s

14.2 Resultados AUC-ROC




Figura 37: AUC-ROC por modelo y etiqueta. Rango de color 0.90-1.00.




Figura 38: Metricas macro: AUC-ROC, F1 y F2 por modelo.

LinearSVC alcanza el AUC macro mas alto (0.9724), seguido por LR L1 (0.9705). La cadena LightGBM tiene AUC macro de 0.9470, inferior a todos los modelos lineales excepto SGD. MultinomialNB y ComplementNB son competitivos en AUC (0.96 y 0.96) a pesar de supuestos violados, pero su F1 y F2 son significativamente menores.

14.3 Resultados F1 y F2

En F1 y F2 (que miden rendimiento con umbral de decision), LinearSVC y LR L1 dominan. La cadena LightGBM tiene F1 macro 0.49, inferior al F1 de LinearSVC (0.55). ComplementNB colapsa en F1 (0.12) porque sus predicciones estan mal calibradas y los umbrales F2-optimos no compensan. SGDClassifier falla completamente (AUC 0.61) porque el early stopping detiene el entrenamiento prematuramente con datos desbalanceados.

14.4 Calibracion

LinearSVC con CalibratedClassifierCV (sigmoid) tiene el mejor ECE macro (0.0037). MultinomialNB tiene ECE 0.006. LR L1 tiene el peor ECE (0.10) entre los modelos funcionales. ComplementNB tiene ECE catastrofico (0.46). La calibracion de LinearSVC es notablemente superior porque Platt scaling con CV produce probabilidades bien calibradas, mientras que los arboles de LightGBM y los scores de LR L1 sobre features sparse tienden a sobrecalibrar.

14.5 Evaluacion de hipotesis

H12 (NB mejor en prevalentes que en raras): REFUTADA. MultinomialNB tiene AUC relativamente mejor en etiquetas raras (delta -0.008 vs LR) que en prevalentes (delta -0.017). Esto contradice la intuicion de que el supuesto de independencia falla mas donde hay menos datos. La explicacion alternativa es que TF-IDF de n-gramas produce features suficientemente decorrelacionadas para que NB funcione razonablemente, independientemente de la frecuencia de la etiqueta. El supuesto de independencia condicional de NB se aplica a features dado la clase, no a etiquetas entre si.

H13 (LinearSVC supera LR en F1): CONFIRMADA. LinearSVC tiene F1 macro 0.5548 vs LR 0.5484 (delta $+0.006$). La diferencia es pequena pero consistente: LinearSVC supera a LR en 5 de 6 etiquetas en F1. La ventaja viene de hinge loss, que optimiza el margen directamente y produce predicciones mas confiables cerca del umbral. Ademas, LinearSVC con calibracion Platt scaling tiene ECE 10x menor que LR, lo que hace que los umbrales F2-optimos sean mas estables.

H14 (Chain supera independientes en etiquetas posteriores): REFUTADA. La cadena tiene AUC 0.9445 en severe_toxic + identity_hate + threat, vs LR con 0.9732 (delta -0.029). Los modelos independientes superan a la cadena en todas las etiquetas posteriores. La razon es que LightGBM con 200-1000 arboles y features sparse de 5000 dimensiones sobreajusta las probabilidades de la cadena, que se convierten en features dominantes pero ruidosas en test. La cadena funciona cuando las predicciones intermedias son calibradas y confiables, pero LightGBM produce probabilidades sobrecalibradas (ECE 0.12 en toxic) que propagan error a las etiquetas posteriores.




Figura 39: AUC-ROC por etiqueta y modelo (radar). La ventaja de LinearSVC es consistente en todas las etiquetas.

14.6 Implicacion clave: LinearSVC como modelo productivo

LinearSVC con calibracion Platt scaling es el mejor modelo CPU-only para este problema. Tiene el AUC mas alto (0.9724), el F1 mas alto (0.5548), la mejor calibracion (ECE 0.004) y entrena en 58 segundos vs 888 segundos de LightGBM. La combinacion de hinge loss (buen margen) + Platt scaling (buena calibracion) + class_weight balanced (manejo de desbalance) lo hace superior a LR en todos los aspectos que importan para deploy.

La cadena de LightGBM no es el mejor modelo para este problema. Su ventaja teorica (modelar dependencias entre etiquetas) se anula porque las probabilidades intermedias estan mal calibradas y propagan error. Un LinearSVC independiente por etiqueta con predicciones bien calibradas es mas robusto.

15 Conclusiones

H1 confirmada. Ningún par de etiquetas es independiente (Chi-cuadrada $p < 0.001$ en todos los casos). **severe_toxic** es un subconjunto perfecto de **toxic**. **obscene** e **insult** co-ocurren en más del 70% de los casos. Esta estructura invalida el supuesto de independencia de clasificadores binarios separados y favorece modelos multietiqueta que capturen la covarianza entre etiquetas.

H2 parcialmente confirmada. Los comentarios tóxicos son más cortos (media 303 vs 404 caracteres) y usan más mayúsculas (ratio 0.111 vs 0.045). Los features de énfasis (**caps_ratio**, **exclaim_ratio**) tienen el mayor tamaño de efecto, pero las distribuciones se solapan sustancialmente. Los features simples capturan solo una fracción de la señal discriminativa.

H3 confirmada. La clase mayoritaria (comentarios limpios) es 89.83% del dataset. La exactitud trivialmente alcanza 90% prediciendo siempre «no tóxico». F1-score y AUC-ROC son necesarias como métricas primarias porque son robustas al desbalance, aunque ninguna es suficiente sola. F1 depende del umbral de decisión y AUC no refleja el costo asimétrico de errores en moderación real.

H4 confirmada con matiz. Los baselines con features simples alcanzan AUC-ROC entre 0.56 y 0.79, lejos del rendimiento competitivo ($AUC > 0.95$). Los intervalos de confianza sobre 10 semillas confirman que Random Forest supera significativamente a LogisticRegression en F1 y AUC para las etiquetas prevalentes (**toxic**, **obscene**, **insult**). Sin embargo, para las etiquetas raras (**threat**, **identity_hate**) los intervalos se solapan y la diferencia no es estadísticamente significativa. El coeficiente de variación del F1 para **threat** con Random Forest es 33.9%, lo que indica que la métrica es intrínsecamente inestable con tan pocos positivos.

H5 confirmada y cuantificada. **threat** (0.30%) e **identity_hate** (0.88%) obtienen los F1 más bajos y tienen la menor co-ocurrencia con las demás etiquetas. El análisis de estabilidad muestra que sus métricas son tan ruidosas que no permiten distinguir entre algoritmos. La escasez extrema de ejemplos positivos (478 para **threat** en el dataset completo, 93 en la submuestra) hace que la varianza del estimador domine la señal. Soluciones como oversampling dirigido, data augmentation textual o transfer learning son necesarias para estas etiquetas.

Estructura jerárquica. Las etiquetas no forman un orden parcial estricto. La única implicación perfecta es **severe_toxic** $\rightarrow$ **toxic**. Las demás sub-etiquetas son subconjuntos aproximados de **toxic** con tasas de violación entre 6% y 7.3%. Las 523 excepciones de **obscene**=1 sin **toxic**=1 incluyen comentarios con lenguaje vulgar que los anotadores no consideraron genéricamente tóxicos. Esta estructura puede explotarse con una arquitectura jerárquica (detectar **toxic** primero, luego sub-tipo) o con una pérdida que penalice las violaciones de la jerarquía.

Defensa del modelo baseline. LogisticRegression con **class_weight="balanced"** es preferible a Random Forest como baseline inicial para las etiquetas prevalentes porque ofrece interpretabilidad directa, entrenamiento rápido y AUC comparable. Para las etiquetas raras, ningún modelo con features simples es confiable (IC amplios, $CV > 10\%$). El modelo productivo debe ser multietiqueta con representación textual rica.

Sentimiento y categorías temáticas. VADER (valencia) y EMPATH (tema) capturan dimensiones parcialmente independientes que mejoran significativamente el baseline. La combinación texto+VADER+EMPATH alcanza AUC de 0.84 a 0.94, un salto de +0.17 a +0.31 sobre solo texto. VADER **sent_neg** es el feature individual más potente para la mayoría de

etiquetas, pero EMPATH kill supera a VADER en threat. Los 3,075 comentarios toxicos con sentimiento positivo ilustran la limitacion de los modelos lexicos. La combinacion completa (texto + VADER + EMPATH) sistematicamente supera a cualquier subconjunto, confirmando que las tres dimensiones son complementarias.

Modelo productivo: LinearSVC con calibracion Platt. La comparacion de seis modelos CPU-only revela que LinearSVC con CalibratedClassifierCV (sigmoid) es el mejor modelo: AUC macro 0.9724, F1 macro 0.5548, ECE macro 0.0037. Supera a LogisticRegression en AUC, F1 y calibracion. Supera a la cadena LightGBM en AUC (0.9724 vs 0.9470) y F1 (0.5548 vs 0.4917) porque las probabilidades intermedias de la cadena propagan error al estar mal calibradas. MultinomialNB es sorprendentemente competitivo en AUC (0.9564) a pesar del supuesto de independencia violado, pero su F1 es inferior. ComplementNB y SGDClassifier no son viables. La arquitectura de deploy usa LinearSVC como modelo principal con calibracion Platt y umbrales F2-optimos por etiqueta.

Supuestos estadisticos verificados. Las pruebas de normalidad rechazan la normalidad para todos los features ($p < 0.001$), lo que justifica el uso de Mann-Whitney U en lugar de t-test. Las correlaciones Pearson entre etiquetas son validas porque las variables son binarias y el tamano de muestra ($N = 159,571$) garantiza convergencia asintotica. Las pruebas de Chi-cuadrada son validas porque todas las celdas de las tablas de contingencia tienen frecuencias esperadas mayores a 5. El VIF maximo (2.69) indica que no hay multicolinealidad problematica entre etiquetas. Las correlaciones Spearman entre features de VADER y EMPATH son debiles ($r < 0.23$), confirmando que capturan dimensiones independientes.

Limitaciones. Este analisis usa features lexicos (texto simple, VADER, EMPATH) y TF-IDF, que no capturan contexto ni intencion profunda. Las conclusiones sobre poder predictivo son un limite inferior del rendimiento alcanzable con modelos contextuales (BERT, etc.). El dataset proviene de paginas de discusion de Wikipedia en ingles, por lo que los patrones detectados no generalizan necesariamente a otras plataformas, idiomas o contextos culturales. La seleccion de categorias EMPATH basada en correlacion con any_toxic introduce sesgo de seleccion. El umbral F2-optimo para threat (0.10) prioriza recall al extremo y generaria muchos falsos positivos en produccion. La calibracion de toxic (ECE=0.12) indica que las probabilidades no son directamente interpretables sin correccion.

Herramientas de IA utilizadas: Claude (generación de código y estructura del análisis), Typst (composición del reporte).